

רגרסייה ליניארית – רוצים להביא למינימום את פונקציית המרחק המחיר $E_{in}(\hat{\mathbf{w}}) = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \hat{\mathbf{w}}^T \mathbf{x}_{\mathbf{n}})^2$. מגדירים $X_{N \times (d+1)}$ את מטריצת השרותה והן קטורי הפיצ'רים (התצפיות) והעמדה הראשונה היא עמודת אחדות ואת וקטור התגיונים $\mathbf{y}_{N \times 1}$: ואז: $E_{in}(\hat{\mathbf{w}}) = \frac{1}{N} \| \mathbf{y} - X\hat{\mathbf{w}} \|^2$.

(*) $\left[\|\mathbf{y}\|^2 - 2\mathbf{y}^T X\hat{\mathbf{w}} + \hat{\mathbf{w}}^T X^T X \hat{\mathbf{w}} \right]$ נגזור וגשוו ל-0: $0 = \frac{2}{N} X^T(X\hat{\mathbf{w}} - \mathbf{y}) = 0$

ונקבל את המשוואות הנורמליות: $X^T X \hat{\mathbf{w}} = X^T \mathbf{y}$ (1) ו- $X^T(X\hat{\mathbf{w}} - \mathbf{y}) = 0$ (2). נרצה לקרב את $X\hat{\mathbf{w}}$ ל- \mathbf{y} כך שהשיאה ($X\hat{\mathbf{w}} - \mathbf{y}$) אורתוג' לעומדות X -ול- $X\hat{\mathbf{w}}$ ($\hat{\mathbf{y}} = X\hat{\mathbf{w}}$). נוכל לגזור שוב ולקבל $0 \leq \nabla_{\hat{\mathbf{w}}} E_{in} = \frac{2}{N} X^T X \hat{\mathbf{w}} \geq 0$, $\|X\mathbf{a}\|^2 = (X\mathbf{a})^T(X\mathbf{a}) = \mathbf{a}^T X^T X \mathbf{a}$.

ולכן קונבקסית וכל נקודה שתקיים את המשוואות הנורמליות היא מינ גלובלי. בהנתן ש $X^T X$ הפוכה (X דרגה מלאה) הפרתון למשוואות הנורמליות נובע מהכפלה משמאל בהפיכת לה: $(X^T X)^{-1} X^T X \hat{\mathbf{w}} = (X^T X)^{-1} X^T \mathbf{y}$ נקבל פתרון סגור: $\hat{\mathbf{w}} = (X^T X)^{-1} X^T \mathbf{y}$ ובחין כי כיוון שהפיכה $X^T X \neq 0$ אז $c^T X^T X c \neq 0$ ולכן $> -X^T X$ מכך ניסק שהוא קונבקסית ממשהפתרון שמצאו הוא מינ גלובלי יחידי! החזאי יוגדר בתוך: $\hat{\mathbf{y}} = X\hat{\mathbf{w}} = X \cdot (X^T X)^{-1} X^T \mathbf{y}$ כאשר $H = X(X^T X)^{-1} X^T$ היא מטריצה המשילה את \mathbf{y} (סימטרית ו-1).

$\|\hat{\mathbf{y}} - \mathbf{y}\|^2 = H(H^T - H)$ על עמודות X כש- $\hat{\mathbf{y}}$ ההיטל. השיאה הסופית שמתבסת על המשוואות הנורמליות תניב לנו את משפט פיתגורס: $\|\hat{\mathbf{y}} - \mathbf{y}\|^2 = \|\mathbf{y} - X\hat{\mathbf{w}}\|^2 = (\mathbf{y} - X\hat{\mathbf{w}})^T(\mathbf{y} - X\hat{\mathbf{w}}) = \mathbf{y}^T(\mathbf{y} - X\hat{\mathbf{w}}) = \|\mathbf{y}\|^2 - \mathbf{y}^T X \hat{\mathbf{w}} = \|\mathbf{y}\|^2 - \hat{\mathbf{w}}^T X^T X \hat{\mathbf{w}} = \|\mathbf{y}\|^2 - \|\hat{\mathbf{y}}\|^2$ לא מדורה מלאה אז $X^T X$ לא הפוכה יש אינסוף פתרונות עבור $\hat{\mathbf{w}}$ שהפרש ביניהם בגרעין של X . אך פתרון יחיד עבור $X\hat{\mathbf{w}} = \hat{\mathbf{y}}$ הוא היטל ולכן כל הפתרונות של $\hat{\mathbf{w}}$ משיגים את אותה שיאה מינימלית כי E_{in} קונבקסית ו $0 < X^T X$ וש נק' מינ'. דרך נוספת לפתרון היא השלמה ריבונית עבור (*) כאשר מניחים ש- $0 < X^T X$: בטישו $\tilde{\mathbf{w}}^T X^T X \hat{\mathbf{w}}$ קל להגיע אך צריך להוסיף את $-2\mathbf{y}^T X \hat{\mathbf{w}}$ נתחיל מ- $(\hat{\mathbf{w}} - b)^T X^T X (\hat{\mathbf{w}} - b)$ ועל מנת שיתקיים: $-\mathbf{y}^T X \hat{\mathbf{w}} = -b^T X^T X \hat{\mathbf{w}}$ נגדיר: $b = (X^T X)^{-1} X^T \mathbf{y}$, מצבים, מוסיפים קבועים ומקבלים את הביטוי הרלוונטי: $\frac{1}{N} [(\hat{\mathbf{w}} - (X^T X)^{-1} X^T \mathbf{y})^T (X^T X)(\hat{\mathbf{w}} - (X^T X)^{-1} X^T \mathbf{y}) + \|\mathbf{y}\|^2 - \mathbf{y}^T X (X^T X)^{-1} X^T \mathbf{y}]$ כאשר $0 < X^T X$ והכפל השמאלי בסוגריים המרובעים אי-שלילי והבתוו למינימום לפי $\mathbf{c}^T X^T X \mathbf{c} = 0$ מחייבת שיתאפש משמע $\mathbf{c} = 0$: ולכן: $\hat{\mathbf{w}} = (X^T X)^{-1} X^T \mathbf{y}$:

ראשונו היא אחדות) ונטמן $\hat{\mathbf{y}} = X\hat{\mathbf{w}}$ אז מ(1) נקבל ש- $X^T \hat{\mathbf{y}} = X^T \mathbf{y}$ בפרט מתקיים שוויון בעמדה הראשונה: $1^T \hat{\mathbf{y}} = 1^T \mathbf{y}$ מה שמשלך על כך שהממצעים של ערכי $\hat{\mathbf{y}}$ ו- \mathbf{y} שווים: $\frac{1}{N} \sum_{n=1}^N \hat{y}_n = \frac{1}{N} \sum_{n=1}^N y_n$ וממוצע השיאות הוא 0.

נקודה חשובה: אם היינו יודעים על התוחלת $E[(\mathbf{y} - x^T \hat{\mathbf{w}})^2] = 0$ היינו יכולים לתלות את הפונקציית הצפיפות הפילו המשותפת ואז היינו מקבלים את הפתרון האופטימלי על ידי גזירה: $E[\partial/\partial \hat{\mathbf{w}} (\mathbf{y} - x^T \hat{\mathbf{w}})] = 0 \Rightarrow \hat{\mathbf{w}} = (E[\mathbf{xx}^T])^{-1} \cdot E[x\mathbf{y}]$ כאשר $E[x\mathbf{y}] = -2(E[x\mathbf{y}] - E[\mathbf{xx}^T]\hat{\mathbf{w}}) = 0$

יש x עם עצמו. והמשערך האופטימלי מושגת על התוחלת הסטטיסטית, אך מכיוון שאחנו לא יודעים את פונ' הצפיפות - אנחנו מנסים להביא למינימום את ממוצע שיאות המרחקים שהוא מושגת על תוחלת אמפירית (כל התוחלות במשערך האופטימלי הופכות לממוצעים). אפשר לבצע טרנס' לא ליניארית על מנת לעבור למרחב אחוז Z בו המטריצת שורות שלנו: $X = x_i^j, i = 1, \dots, N, j = 0, \dots, d$ (עמודה ראשונה 1 היא מטריצת ונדומנדו שדרגתה כמו x_i -ים השונים זה מזה).

רגרסייה לוגיסטית – רוצים להניב $\hat{y} \in [0, 1]$ ע"י הלברשת סיגרמיד $\sigma(s) = \frac{e^s}{1+e^s} = \frac{1}{1+e^{-s}}$ על המשערך כאשר:

$\theta(-s) = 1 - \theta(s), \quad \theta'(s) = \theta(s) \cdot (1 - \theta(s))$ משמע $h(\mathbf{x}) = \theta(\mathbf{w}^T \mathbf{x})$ ורוצים ללמוד את ההסתברות $P(y = 1 | \mathbf{x})$. משתמשים בשיאת cross-entropy לשוקחת 2 פונ' הסתברות של משתנים בינאריים: $(p, 1-p), (q, 1-q)$ ומחדדת את המרחק ביניהן. פונקציית השיאה $h(\mathbf{x}_n) := \theta(\mathbf{w}^T \mathbf{x}_n)$:

$h(\mathbf{x}_n) = \theta(\mathbf{w}^T \mathbf{x}_n) \rightarrow 1$ נרצה $y_n = +1$ עבור $E_{in}(\hat{\mathbf{w}}) = \frac{1}{N} \sum_{n=1}^N I(y_n = +1) \log \left(\frac{1}{\theta(\mathbf{w}^T \mathbf{x}_n)} \right) + I(y_n = -1) \cdot \log \left(\frac{1}{\theta(\mathbf{w}^T \mathbf{x}_n)} \right)$ עבור $y_n = -1$ נרצה $h(\mathbf{x}_n) = \theta(-\mathbf{w}^T \mathbf{x}_n) \rightarrow 1$. עם זאת נבחין שאפשרי להכניס את ערכי y_n לתוך θ (התוצאה לא תשתנה) ונקבל: $E_{in}(\hat{\mathbf{w}}) = \frac{1}{N} \sum_{n=1}^N I(y_n = +1) \log \left(\frac{1}{\theta(y_n \mathbf{w}^T \mathbf{x}_n)} \right) + I(y_n = -1) \cdot \log \left(\frac{1}{\theta(y_n \mathbf{w}^T \mathbf{x}_n)} \right)$

[cross-entropy של $I(y_n = +1) + I(y_n = -1)$] סכום האנדיקטורים הוא 1 ונקבל את פונקציית השיאה הסופית של cross-entropy:

$\frac{\partial}{\partial \hat{\mathbf{w}}} E_{in}(\hat{\mathbf{w}}) = \frac{\partial}{\partial \hat{\mathbf{w}}} \frac{1}{N} \sum_{n=1}^N \log(1 + e^{-y_n \hat{\mathbf{w}}^T \mathbf{x}_n}) = \frac{1}{N} \sum_{n=1}^N \log(1 + e^{-y_n \hat{\mathbf{w}}^T \mathbf{x}_n})$: אותו נרצה להביא למינימום, נגזור:

$\nabla_{\hat{\mathbf{w}}} E_{in}(\hat{\mathbf{w}}) = -\frac{1}{N} \sum_{n=1}^N \frac{e^{-y_n \hat{\mathbf{w}}^T \mathbf{x}_n}}{1 + e^{-y_n \hat{\mathbf{w}}^T \mathbf{x}_n}} \cdot (y_n \mathbf{x}_n)$ ניפה: $\frac{1}{N} \sum_{n=1}^N (1 + e^{-y_n \hat{\mathbf{w}}^T \mathbf{x}_n})^{-1} \cdot e^{-y_n \hat{\mathbf{w}}^T \mathbf{x}_n} \cdot (-y_n \mathbf{x}_n)$ ונראה שאין פתרון סגור:

$-\frac{1}{N} \sum_{n=1}^N \theta(-y_n \hat{\mathbf{w}}^T \mathbf{x}_n) (y_n \mathbf{x}_n) = 0$ Gradient - Descent . נבחין גם כי זו פונקציית קונבקסית כי הגזרת השנייה (הסיקה): $\nabla^2 E_{in} = \frac{1}{N} \sum_{n=1}^N \theta(-y_n \hat{\mathbf{w}}^T \mathbf{x}_n) (1 - \theta(-y_n \hat{\mathbf{w}}^T \mathbf{x}_n)) (-y_n \mathbf{x}_n \mathbf{x}_n^T)$

[illegible]

5

$ln(f(x))' = \frac{1}{x} \cdot f'(x)$ •

כלל השרשרת: $h'(x) = f'(g(x))g'(x)$ •

מכפלה $h'(x) = f'(x)g(x) + g'(x)f(x)$ •

חלוקה: $(f(x)/g(x))' = \frac{f'(x)g(x) - g'(x)f(x)}{g(x)^2}$ •

$\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$ ריבועיות: A, B ועבור $\text{tr}(ABCD) = \text{tr}(BCDA) = \text{tr}(CDAB) = \text{tr}(DABC)$

מטריצות קרוס-קוואריאנס:

$C_{xx} = \frac{1}{N} \sum_{n=1}^N (x_i - \bar{x})^2; C_{xy} = \frac{1}{N} \sum_{n=1}^N (x_i - \bar{x})(y_i - \bar{y}); C_{yy} = \frac{1}{N} \sum_{n=1}^N (y_i - \bar{y})^2$